



Relatório Técnico

1. Nome do Grupo:

autonomia (3)

2. Componentes Remanescentes do Grupo:

Cláudio Teixeira (Líder), Jorge Marcondes e Patrick Angrezani

3. Descrição do Tema Escolhido:

O SICOF é um sistema de Inteligência Artificial desenvolvido para automatizar a análise, classificação e gestão de documentos fiscais eletrônicos (NF-e). Sua proposta central é oferecer uma solução inteligente capaz de classificar, categorizar e personalizar ações contábeis e tributárias de acordo com o ramo de atividade da empresa ou instituição, combinando algoritmos de aprendizado de máquina supervisionado com agentes de linguagem natural (LLMs).

Concebido inicialmente para atender às demandas de instituições públicas que enfrentam um alto volume de notas fiscais eletrônicas e regras tributárias complexas, o SICOF foi projetado para organizar, arquivar e analisar documentos fiscais de forma automática, fornecendo ao mesmo tempo diagnósticos de conformidade e identificação de riscos tributários.

A solução baseia-se em três pilares fundamentais:

1. Classificação automática de documentos fiscais: identifica o tipo de operação (compra, venda, serviço) e estrutura os arquivos XML em um banco de dados normalizado, reduzindo a necessidade de intervenção manual.
2. Categorização semântica por centros de custo e natureza de despesa: utiliza modelos de linguagem natural (OpenAI GPT via LangChain) para agrupar documentos por similaridade contextual, interpretando descrições e aplicando semântica contábil.
3. Customização fiscal conforme o ramo de atividade: aplica regras tributárias específicas de cada setor econômico, permitindo diagnósticos e recomendações automatizadas adaptadas à realidade de cada organização. Por exemplo, no Agronegócio, o SICOFF pode ser utilizado para monitorar CFOPs específicos relacionados à venda de produtos agrícolas e aquisição de insumos, calculando impostos com particularidades do setor. No Setor Automotivo, o SICOFF pode ser utilizado na validação de notas fiscais de peças e serviços, na verificação de códigos de compatibilidade e, assim, assegurar a coerência com as atividades da empresa. Já na Indústria, o SICOFF pode ser utilizado para realizar apurações de impostos específicos (como IPI e Substituição Tributária) e gerar insumos para o cálculo de custos de produção.

Essa diversa abordagem permite que o SICOFF vá além da simples leitura de arquivos XML, interpretando o contexto das transações e aplicando regras fiscais parametrizadas por domínio. Graças ao seu comportamento adaptativo, o SICOFF configura-se como uma ferramenta flexível e escalável, capaz de se ajustar automaticamente às particularidades de diferentes contextos empresariais ou institucionais. Ao integrar machine learning, processamento de linguagem natural e regras fiscais parametrizadas, o sistema reduz a carga de trabalho humano, minimiza erros, aumenta a produtividade e melhora a governança fiscal.

4. Público-Alvo:

O SICOFF foi projetado para profissionais (servidores) e instituições públicas que lidam com grandes volumes de documentos fiscais, oferecendo uma solução automatizada, segura e auditável para a gestão e análise tributária. Seu público-alvo abrange diversos segmentos que

compartilham a necessidade de otimizar processos, reduzir custos operacionais e assegurar conformidade fiscal.

Entre os principais usuários potenciais estão departamentos de controladoria, compliance e finanças corporativas, interessados em automatizar a validação de informações fiscais e o monitoramento de riscos tributários, e instituições públicas e órgãos de fiscalização que demandam transparência, rastreabilidade e eficiência na análise de grandes bases de dados fiscais.

Em síntese, o SICOF destina-se a profissionais e organizações públicas que necessitam reduzir o tempo e o custo de análise, garantindo regularidade, padronização e rastreabilidade em suas operações fiscais e contábeis. Trata-se de uma ferramenta estratégica voltada à transformação digital da gestão tributária, unindo inteligência artificial, aprendizado de máquina e interpretação semântica para tornar o processo mais eficiente, confiável e escalável.

5. Justificativa do Tema Escolhido:

A classificação manual de notas fiscais é um processo moroso, suscetível a erros e altamente dependente de conhecimento técnico especializado. Com a crescente digitalização das obrigações acessórias e a complexidade do sistema tributário brasileiro, torna-se cada vez mais necessário adotar soluções inteligentes que unam precisão analítica, atualização normativa contínua e capacidade interpretativa.

Neste contexto, o SICOF surge como resposta a esse desafio, oferecendo uma plataforma de Inteligência Artificial aplicada à gestão fiscal que automatiza processos críticos e amplia a eficiência operacional.

Entre os principais benefícios da utilização do SICOF inclui-se: (i) a automatização de processos essenciais de leitura, classificação e arquivamento de notas fiscais eletrônicas (NF-e); (ii) a detecção precoce de inconsistências fiscais e tributárias, reduzindo riscos e retrabalho; (iii) a geração de relatórios explicativos e rastreáveis, compreensíveis mesmo para usuários sem formação contábil; (iv) a customização por ramo de atividade, atendendo às especificidades de setores como agronegócio, indústria, serviços, setor público e terceiro setor; (v) o valor agregado por meio de previsões, alertas e auditorias automáticas baseadas

em Inteligência Artificial, fortalecendo a governança fiscal e a transparência institucional. Em síntese, o projeto responde a uma necessidade real e crescente enfrentada por empresas e instituições brasileiras: como lidar com o alto volume de dados fiscais e a complexidade das normas tributárias, sem comprometer a conformidade e a eficiência.

A escolha do tema justifica-se pela urgência de modernização e automação no campo da contabilidade digital. Em um ambiente caracterizado por mudanças constantes na legislação e expansão exponencial do volume de informações, torna-se imprescindível adotar ferramentas que combinem rigor algorítmico com interpretação semântica contextual.

O SICOF agrega valor ao permitir a detecção automatizada de inconsistências, a geração de relatórios claros e interpretáveis e a parametrização de regras fiscais específicas para cada setor econômico. Com isso, o sistema contribui não apenas para a redução de erros e retrabalho, mas também para o fortalecimento da cultura de conformidade e transparência tributária.

Ao integrar modelos de aprendizado de máquina supervisionado e modelos de linguagem natural (LLMs), o SICOF adota uma abordagem híbrida e inovadora, capaz de unir a robustez estatística da análise automatizada à inteligibilidade das explicações em linguagem natural, tornando o processo de auditoria fiscal mais eficiente, confiável e acessível.

6. Como o SICOF foi construído:

Do ponto de vista técnico, o SICOF foi desenvolvido em Python e estruturado em módulos interdependentes, o que garante clareza arquitetural, manutenção simplificada e escalabilidade.

O fluxo operacional inicia-se no módulo de ingestão de dados, responsável por converter arquivos XML de notas fiscais eletrônicas (NF-e) em DataFrames estruturados, utilizando a biblioteca lxml para tratamento de *namespaces* e extração de metadados fiscais.

Na sequência, o pipeline de pré-processamento realiza a normalização e transformação das variáveis numéricas, categóricas e textuais, aplicando vetorização TF-IDF às descrições de produtos e codificação one-hot para atributos categóricos.

A etapa de classificação supervisionada é conduzida por um modelo `RandomForestClassifier`, treinado para identificar o tipo de operação fiscal com base em padrões de atributos. Paralelamente, o módulo de detecção de anomalias, implementado com `IsolationForest`, identifica inconsistências e desvios em relação ao comportamento esperado. Ambos os modelos são integrados em um pipeline unificado e persistidos via `joblib`, assegurando sua reutilização e rastreabilidade em análises futuras.

A dimensão semântica do sistema é complementada por um agente de linguagem natural, desenvolvido com `LangChain` e `OpenAI GPT`, configurado para interpretar descrições textuais e sugerir agrupamentos contábeis coerentes. Esse agente classifica as notas fiscais em três dimensões principais: centro de custo, natureza da despesa e finalidade da operação. Os resultados são validados com `PydanticOutputParser`, garantindo consistência, integridade e auditabilidade dos dados.

As regras de negócio e customizações fiscais estão concentradas no módulo `utils.py`, que contém mapeamentos entre CNAE e ramos de atividade, listas de CFOP e NCM por setor, além de funções específicas para emissão de alertas fiscais automatizados. Essas rotinas detectam incongruências comuns — como CFOPs inadequados, códigos de produtos incompatíveis ou ausência de tributos obrigatórios — transformando o sistema em um mecanismo inteligente de diagnóstico e recomendação fiscal, e não apenas em uma ferramenta de classificação.

A interface do usuário, construída em `Streamlit`, permite o upload de múltiplos XMLs, a execução dos modelos em lote, a visualização dos resultados em tabelas e gráficos e o download automático de relatórios compactados. A aplicação pode ser executada localmente ou implantada na nuvem, sendo totalmente compatível com o `Google Cloud Run`, que garante escalabilidade horizontal, segurança e disponibilidade contínua.

O backend, implementado em `FastAPI`, recebe os arquivos enviados pela interface e coordena o processamento dos dados, acionando os modelos de `Machine Learning` e o agente de linguagem natural (LLM). O resultado final inclui:

- Classificação das notas por tipo de operação e centro de custo;
- Detecção de anomalias fiscais;
- Agrupamentos semânticos e diagnósticos automatizados;
- Relatórios estruturados em JSON e pacotes ZIP contendo os XMLs reorganizados.

Todo o processo é automatizado, auditável e reproduzível, preservando rastreabilidade e integridade dos resultados.

Estrutura Técnica e Arquitetura Modular do SICOF:

Camada	Arquivo	Função Principal
Ingestão de Dados	xml_parser.py	Converte arquivos XML de NF-e em DataFrames estruturados
Pré-processamento	pipelines.py	Normaliza e vetoriza colunas numéricas, categóricas e textuais
Classificação Supervisionada	classifier.py	Utiliza RandomForest para identificar categorias fiscais
Detecção de Anomalias	detector.py	Emprega IsolationForest para identificar inconsistências tributárias
Agrupamento Semântico (LLM)	grouping_agent.py	Interpreta descrições e agrupa notas por centro de custo
Regras de Negócio e Customização	utils.py	Aplica validações específicas para agronegócio, indústria e serviços
Interface Web	app_interface.py	Permite upload, visualização e download de relatórios
API Principal	main.py	Integra FastAPI, LLM e modelos de ML em um pipeline unificado
Configuração	settings.py	Gerencia variáveis de ambiente, incluindo OPENAI_API_KEY

Tecnologias Utilizadas

- Python 3.12, FastAPI, Streamlit, scikit-learn, pandas, joblib
- LangChain, OpenAI API, Pydantic, lxml, matplotlib
- Google Cloud Run para implantação escalável via contêiner Docker

Implantação em Nuvem (Google Cloud Run)

O processo de *deploy* foi estruturado para garantir portabilidade e automação contínua:

1. Criação do projeto e do repositório no Artifact Registry;
2. Construção da imagem Docker com código e dependências;
3. Deploy automatizado via comando `gcloud run deploy`;
4. Configuração da variável `OPENAI_API_KEY` no painel do serviço;
5. Disponibilização de URL pública para execução e testes.


Essa infraestrutura permite processamento simultâneo de centenas de notas fiscais, assegurando alto desempenho e escalabilidade horizontal.

Estrutura Funcional do SICOF

O diagrama conceitual do SICOF representa um fluxo vertical de processamento inteligente, desde a entrada dos arquivos XML até a geração dos relatórios e pacotes consolidados. O sistema opera em camadas funcionais integradas, que se comunicam por meio de uma API central e de um modelo de linguagem (LLM) que agrega interpretação semântica e contexto fiscal. As etapas funcionais do SICOF estão descritas e ilustradas abaixo (ver Diagrama):

1. Interface Web (Streamlit)

A interação do usuário com o sistema ocorre por meio da interface desenvolvida em Streamlit, que permite o envio dos arquivos XML de notas fiscais eletrônicas. O usuário pode realizar o upload de múltiplos documentos simultaneamente, acompanhar o progresso do processamento e visualizar os resultados em tempo real. Essa camada atua como o ponto de entrada de dados e também como ambiente de exibição dos relatórios finais, facilitando a experiência de uso sem necessidade de configuração técnica.



2. API (FastAPI)

A API desenvolvida em FastAPI funciona como núcleo de comunicação entre a interface e os módulos internos do sistema. Após o envio dos arquivos, ela recebe as requisições, interpreta as instruções do usuário e encaminha os dados aos modelos de Machine Learning e ao LLM. Essa camada é responsável por garantir a integração e a troca eficiente de informações entre os componentes, mantendo o desempenho e a escalabilidade da aplicação. Ela também trata requisições assíncronas e controla as respostas geradas por cada módulo de análise.

3. Modelos de Machine Learning (Classificação e Anomalias)

Nesta camada, os modelos de aprendizado de máquina supervisionado executam as tarefas principais de análise fiscal. O primeiro modelo, do tipo Random Forest, realiza a classificação das notas fiscais, determinando o tipo de operação (compra, venda, serviço) e sua categoria contábil. O segundo modelo, um Isolation Forest, identifica anomalias — valores atípicos, incoerências tributárias ou desvios em relação a padrões históricos. Essa etapa transforma os dados brutos extraídos dos XMLs em informações estruturadas e interpretáveis, compondo a base para a análise semântica posterior.

4. LLM (OpenAI GPT via LangChain)

Após a análise estatística, o sistema utiliza um modelo de linguagem natural (LLM) — especificamente o OpenAI GPT integrado via LangChain — para interpretar as descrições textuais das notas e realizar agrupamentos semânticos. O LLM tem como função principal contextualizar as operações fiscais, associando cada nota a centros de custo, naturezas de despesa e finalidades contábeis. Essa camada introduz um nível de compreensão linguística que complementa o raciocínio quantitativo dos modelos de ML, permitindo que a classificação seja não apenas precisa, mas também explicável em linguagem natural.

5. Regras e Ações Fiscais (utils.py)

A partir das interpretações do LLM, o sistema aciona o módulo de regras e ações fiscais, definido no arquivo utils.py. Essa camada contém funções especializadas que aplicam validações tributárias personalizadas conforme o ramo de atividade (agronegócio, indústria, serviços, setor público etc.). Por exemplo, o SICOF pode verificar automaticamente se os CFOPs utilizados são compatíveis com a operação declarada, calcular tributos específicos

como IPI ou ICMS, ou emitir alertas em caso de inconsistências entre NCM e natureza da transação. Essa lógica de negócios confere ao sistema um comportamento adaptativo, garantindo customização fiscal contextual.

6. Relatórios e Arquivos ZIP Gerados para o Usuário

Após o processamento completo, o sistema consolida todos os resultados em relatórios e pacotes ZIP. O relatório apresenta as classificações, anomalias detectadas, agrupamentos semânticos e recomendações fiscais. Os arquivos ZIP organizam os XMLs reclassificados e podem incluir planilhas Excel com os resultados detalhados, permitindo auditoria, armazenamento e compartilhamento. Essa etapa final representa o fechamento do ciclo de automação: o sistema entrega ao usuário um produto analítico completo, confiável e facilmente verificável.

Essa arquitetura evidencia a integração entre inteligência estatística e linguística, demonstrando como o SICOF combina Machine Learning supervisionado, Processamento de Linguagem Natural e regras fiscais parametrizadas para criar um fluxo contínuo, automatizado, auditável e eficiente de análise fiscal.

Fluxo do Usuário no SICOF

O diagrama abaixo ilustra o fluxo sequencial que o usuário percorre ao interagir com o sistema SICOF (Sistema Inteligente de Classificação, Categorização e Otimização Fiscal), desde o envio dos arquivos até a geração dos relatórios finais. Cada etapa representa um estágio automatizado de análise, articulando machine learning, interpretação semântica e regras fiscais específicas.

Fluxo do Usuário

1 Envio de XMLs de NF-



2 Pré-
processamento e



3 Classificação
Fiscal e



4 Agrupamento
Semântico e



5 Geração e Download de
Relatórios

1. Envio de XMLs de NF-e

O processo se inicia quando o usuário acessa a **interface web** do SICOF e realiza o upload dos arquivos XML de notas fiscais eletrônicas. Esses arquivos contêm informações estruturadas sobre operações comerciais (compra, venda ou prestação de serviços) e servem como insumo primário para todas as etapas seguintes. O sistema é capaz de receber múltiplos arquivos simultaneamente, armazenando-os temporariamente para processamento em lote.

2. Pré-processamento e Extração de Dados

Após o upload, o módulo de parsing lê o conteúdo dos arquivos XML e transforma suas informações em uma estrutura tabular compatível com os modelos de aprendizado de máquina. Essa etapa inclui normalização de campos, correção de inconsistências, eliminação de duplicatas e extração de atributos relevantes, como CFOP, NCM, CNPJ, valores e descrições textuais de produtos e serviços. O resultado é um DataFrame limpo e padronizado, pronto para análise automatizada.

3. Classificação Fiscal e Detecção de Anomalias

Nesta fase, entram em ação os modelos de machine learning supervisionados. O primeiro modelo (Random Forest) realiza a classificação fiscal, determinando o tipo de operação e sua categoria contábil. Em paralelo, um segundo modelo (Isolation Forest) realiza a detecção de anomalias, identificando padrões atípicos que podem indicar inconsistências tributárias ou irregularidades em lançamentos. Essas análises permitem ao sistema antecipar potenciais erros de conformidade fiscal.

4. Agrupamento Semântico e Customização por Ramo

O resultado técnico dos modelos é enriquecido por um modelo de linguagem natural (LLM – OpenAI GPT via LangChain), que interpreta descrições textuais e realiza o agrupamento semântico das notas por centros de custo, natureza de despesa e finalidade. Além disso, o SICOF aplica regras fiscais específicas de cada setor econômico, adaptadas às necessidades de áreas como agronegócio, indústria e serviços. Por exemplo, o sistema pode verificar CFOPs agrícolas, calcular IPI industrial ou conferir códigos de peças no setor automotivo. Essa customização por ramo torna a análise mais precisa e contextualizada.

5. Geração e Download de Relatórios

Concluído o processamento, o SICOF gera relatórios consolidados que reúnem classificações, anomalias, agrupamentos e alertas fiscais. Os resultados são disponibilizados em dois formatos principais: visualização direta na interface (com tabelas e gráficos) e arquivo ZIP contendo planilhas e dados exportáveis. Essa etapa garante que o usuário possa auditar, arquivar ou compartilhar os resultados de forma segura e rastreável.

Desafios e Evolução do Sistema

Os principais desafios enfrentados pelo projeto estão relacionados à adaptação contínua às mudanças legais e fiscais, bem como à diversidade de regimes e setores econômicos, como órgãos públicos, terceiro setor e entidades sem fins lucrativos, que apresentam particularidades tributárias próprias. A arquitetura modular do SICOF, entretanto, facilita a atualização das regras de negócio e a incorporação de novos modelos ou módulos conforme evoluam as demandas regulatórias e tecnológicas, assegurando longevidade, flexibilidade e escalabilidade da solução.

7. Conclusão

O SICOF evidencia o potencial transformador da Inteligência Artificial na automação e qualificação de processos fiscais, reduzindo o esforço manual, o tempo de processamento e o risco de erro humano. Ao integrar modelos estatísticos de aprendizado de máquina com modelos semânticos de linguagem natural, a solução gera valor em dois níveis complementares: operacional, ao oferecer velocidade, precisão e rastreabilidade na classificação e análise de notas fiscais; estratégico, ao promover inteligência fiscal, transparência e suporte à tomada de decisão em tempo real. O projeto adota uma visão adaptável e sustentável, com capacidade de evoluir conforme as mudanças legais e os contextos de negócio, atendendo às especificidades de órgãos públicos. Assim, o SICOF se consolida como uma plataforma inteligente de classificação, categorização e customização fiscal, contribuindo de forma efetiva para a transformação digital e a governança de dados tributários no Brasil.

Em síntese, o SICOF representa uma solução inovadora que alia o rigor analítico dos algoritmos de aprendizado de máquina à flexibilidade e interpretabilidade dos modelos de linguagem natural (LLMs). O sistema automatiza o processo de classificação e auditoria fiscal, fornecendo resultados explicáveis, métricas de desempenho precisas e diagnósticos de conformidade em tempo real. Mais do que uma ferramenta técnica, o SICOF é uma iniciativa estratégica de modernização da gestão tributária, demonstrando o papel da Inteligência Artificial como aliada da eficiência, da transparência e da sustentabilidade fiscal. Ao combinar robustez técnica, aplicabilidade prática e compromisso ético com a automação responsável, o projeto estabelece um marco na transformação digital do setor contábil e financeiro brasileiro, exemplificando o uso inteligente, transparente e sustentável da IA em benefício da administração pública.

8. Link para o repositório do projeto no GitHub

https://github.com/teixeiracec/I2A2_autonomIA_3/tree/main/I2A2%20-%20SICOF